Clasificación Lineal

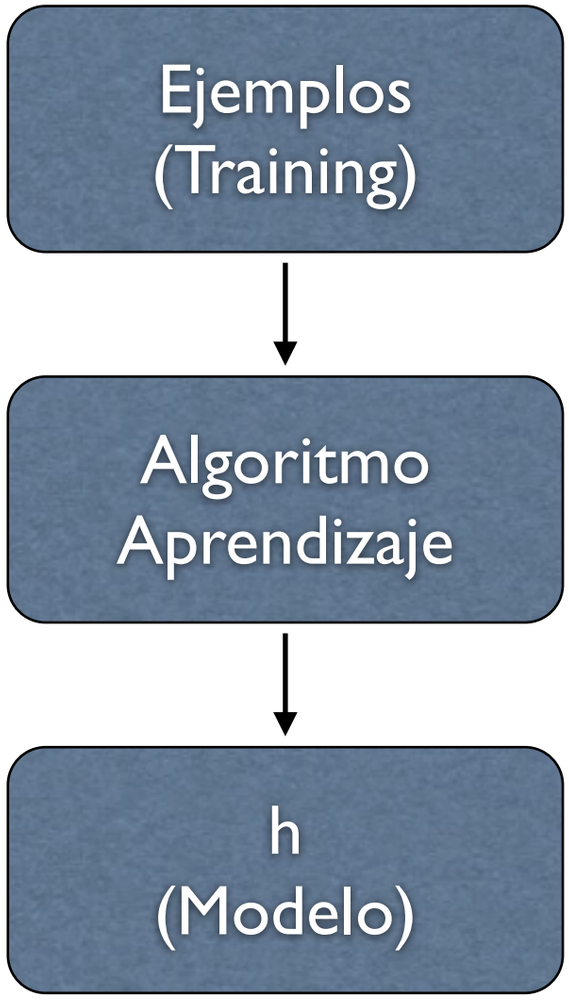
Antonio M. López Rodríguez

Clasificación

- En la clasificación, la variable objetivo es categórica, no numérica, con un conjunto finito de valores.
- Por ejemplo:
  - Diagnosticar la enfermedad de una persona que acude a un centro de urgencias con determinados síntomas, característicos de tres posibles enfermedades (C_0 = bronquitis, C_1 = neumonía, C_2 = gripe).
  - Clasificar un email como spam en base a la presencia de un conjunto de palabras en el encabezado del mensaje (C_0 = no SPAM -falso-, C_1 = SPAM -cierto-).

Planteamiento del Problema

m ejemplos
x's: variables entrada
y: variable salida/objetivo (**categórica**)



x_1	…	x_n	y
x_1^1		x_n^1	c^1
…	…	…	…
x_1^m		x_n^m	c^m

$$y=h(x_1, \ldots, x_n)$$

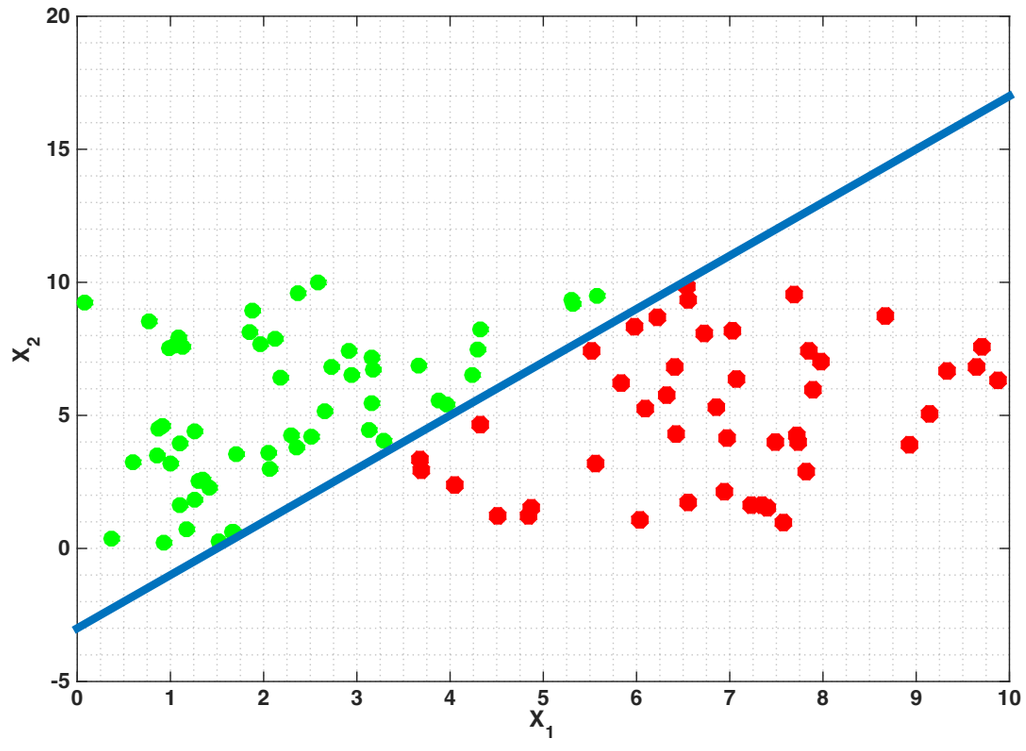
Funciones Discriminantes

- Para abordar el problema de clasificación, buscaremos desarrollar una serie de funciones discriminantes que nos permitan efectuar la clasificación, de manera que dados un conjunto de valores de las características, permitan decidir a qué posible clase objetivo pertenecen.
- Funciones discriminantes: Conjunto de funciones $g_i(x)$ de manera que se asigna x a la clase w_i si $g_i(x)>g_j(x)$ para todo $j\neq i$.
- Si hablamos de un clasificador de dos clases (C_0, C_1), podemos crear una única función discriminante:

  $$g(x)=g_1(x)-g_0(x),$$

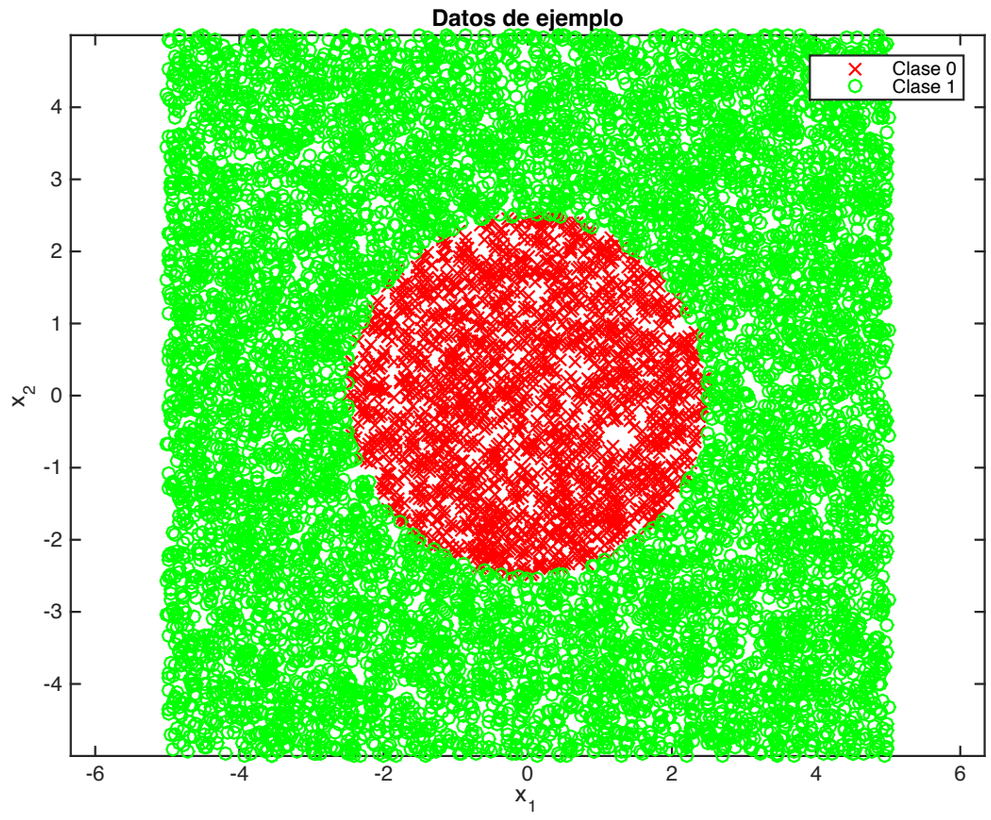
  y decidir C_1 si $g(x)>0$.
- El efecto de un clasificador es dividir el espacio de características en c regiones $R_1,...,Rc$. Las regiones están separadas por un conjunto de superficies de decisión definidas en el espacio de características donde ocurren empates en los valores de dos o más funciones discriminantes.

Funciones Discriminantes Lineales



¿Quién es la función discriminante que separa los puntos verdes de los rojos?

Funciones Discriminantes Lineales



¿Quién es la función discriminante que separa los puntos verdes de los rojos?

Aprendizaje de Funciones Discriminantes

- Nos centraremos directamente en el aprendizaje de las funciones discriminantes. Las asumimos conocidas, salvo sus parámetros, los cuales trataremos de estimar a partir de ejemplos.
- Comenzaremos analizando el problema de separación de dos clases y al final veremos cómo abordar el caso general de clasificación en C clases, C>2.

Funciones Discriminantes Lineales

- Sea x (vector de características) d-dimensional.
- Buscamos g(x) lineal t.q.: *g(x)<0* para $x \in C_0$, *g(x)>0* para $x \in C_1$.

$$g(x) = b_0 + \sum_{i=1}^{d} b_i x_i = \sum_{i=0}^{d} b_i x_i, x_0 = 1$$

- *g(x)* divide el espacio de características mediante:
  - un punto en una dimensión
  - una recta en dos dimensiones
  - un plano en tres dimensiones
  - un “hiperplano” en más dimensiones.
- Un rendimiento óptimo implica que las clases han de ser linealmente separables.

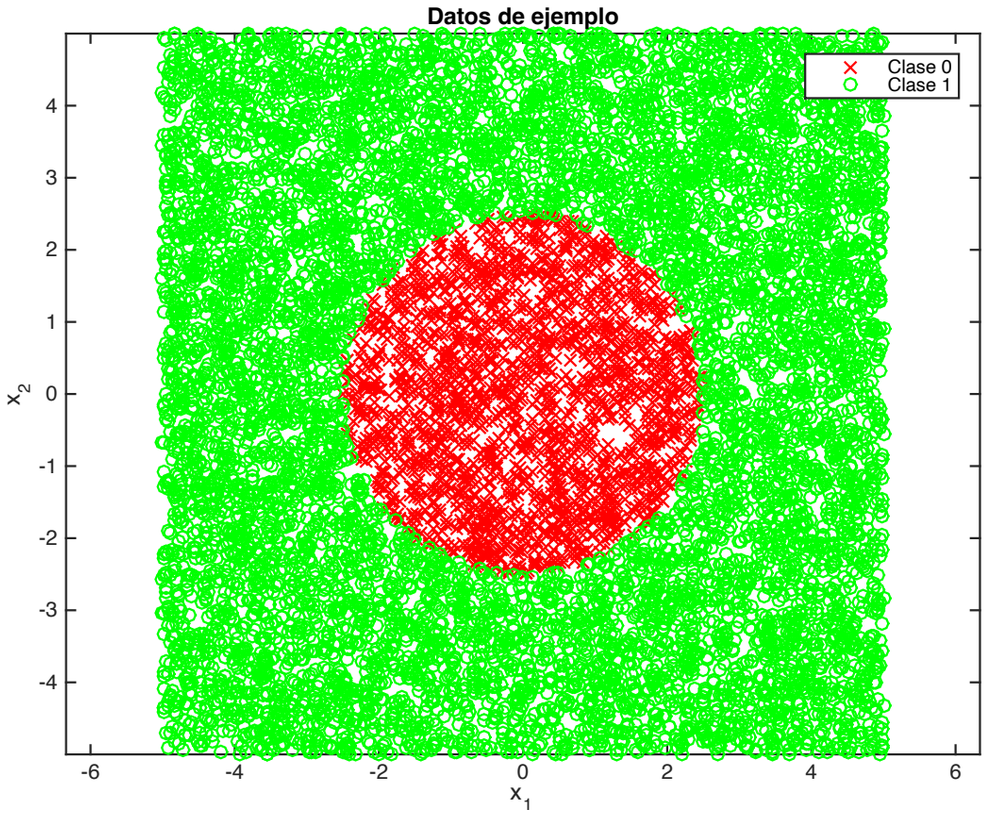
Funciones Discriminantes Lineales Generalizadas

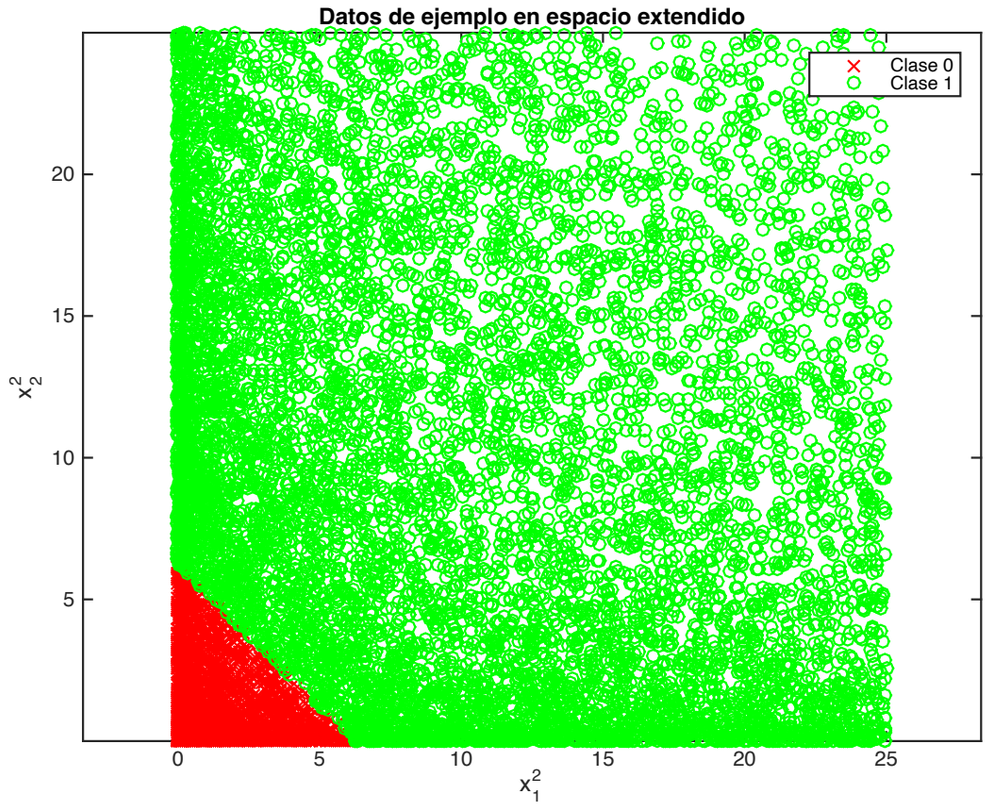
- Sea x (vector de características) d-dimensional.
- Buscamos una función discriminante lineal en un espacio extendido de la forma:

$$z(y) = \sum_{i=0}^{d'} a_i y_i, y_i = f_i(x)$$

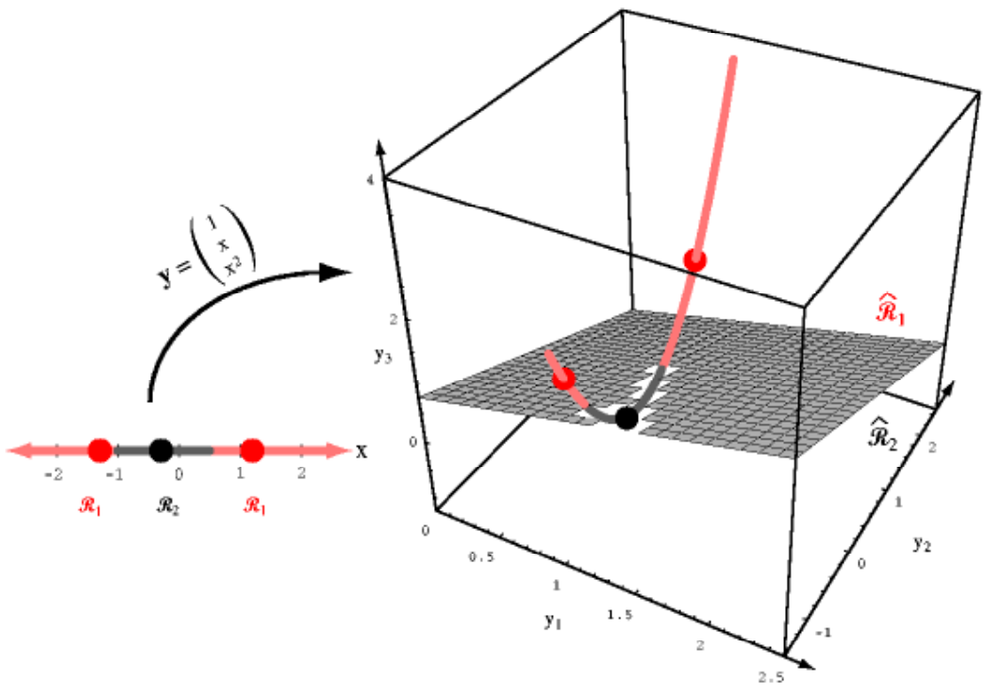
- Buscamos que cumpla $z(y)>0$ para $x \in C_1$, $z(y)<0$ para $x \in C_0$.
- Mediante una correcta selección de d' y las funciones f_i, la expansión lineal enunciada puede aproximar cualquier función discriminante g(x), aún de carácter no lineal (p.e. expansión polinómica según desarrollo en serie de Taylor).
- Incluso con funciones f_i muy simples, las superficies de decisión inducidas en x pueden ser muy complejas.

Ejemplos

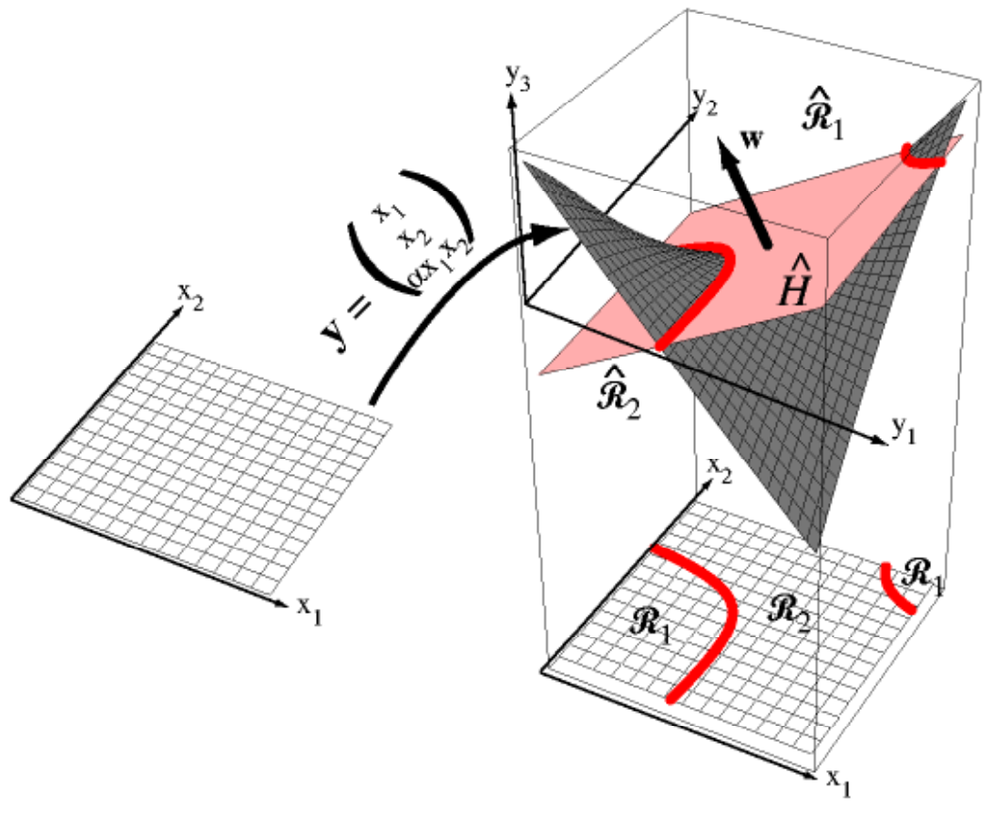

Datos de ejemplo
Clase 0
Clase 1
x_1
x_2


Datos de ejemplo en espacio extendido
Clase 0
Clase 1
x_1^2
x_2^2

Ejemplos




```
>> u = linspace(-5, 5, 100)';
>> y = [ones(100,1) u u.^2];
>> plot3(y(:,1), y(:,2), y(:,3))
>> xlabel("y_1 = 1")
>> ylabel("y_2 = x")
>> zlabel("y_3=x^2")
>> grid on
```



Ajuste de Funciones Discriminantes

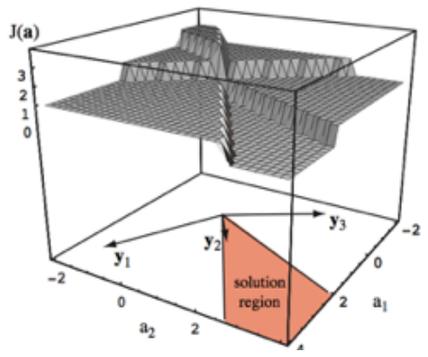
- Sea x (vector de características) d-dimensional. Sea una función discriminante como:

$$z(y) = \sum_{i=0}^{d'} a_i y_i, y_i = f_i(x)$$

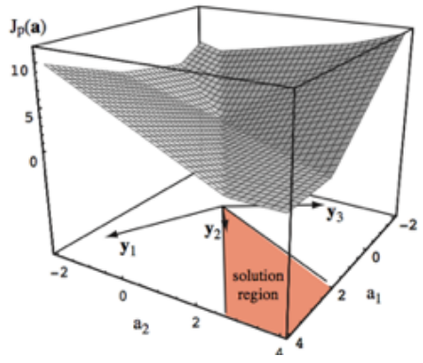
- Disponemos de un conjunto de muestras de ejemplo (entrenamiento) para las cuales conocemos el valor de y (calculado a partir del vector de características x) y la clase asociada (C_0, C_1).
- El objetivo es hallar a_i de manera que la función discriminante separe las muestras de ejemplo (z(y)<0 para ejemplos de clase C_0, z(y)>0 para ejemplos de clase C_1).
- Necesitamos:
  - Una función *J(a)* que sea mínima (deseable cero) para un vector de pesos (*a*) que permite la separación.
  - Un método que nos permita calcular el valor de a que optimiza *J(a)*.
  - Buscaremos por lo general funciones *J(a)* positivas para todo a que cumplan que *J(a)* sea mínimo para a óptimo.
  - Será además deseable que *J(a)* sea derivable, pues permitiría usar información del gradiente para la optimización.
  - Sería igualmente deseable que J(a) fuese convexa, lo cual permitiría aplicar métodos de descenso .

Ajuste de Funciones Discriminantes

- Podemos plantearnos diferentes métodos para la función de coste J(a).
- El algoritmo de optimización dependerá de las características de la función a minimizar (fundamentalmente de si esta es derivable/convexa o no). Es muy común tener que recurrir a algoritmos de descenso de gradiente o incluso a métodos heurísticos o no deterministas cuando el gradiente no está disponible.



Número de muestras mal clasificadas.



Perceptrón.

$$J(a) = \sum |z(y^{(i)})|$$

evaluado para las k muestras mal clasificadas. Mínimo es cero cuando todas las muestras están bien clasificadas.

Ajuste de Funciones Discriminantes: Mínimos cuadrados

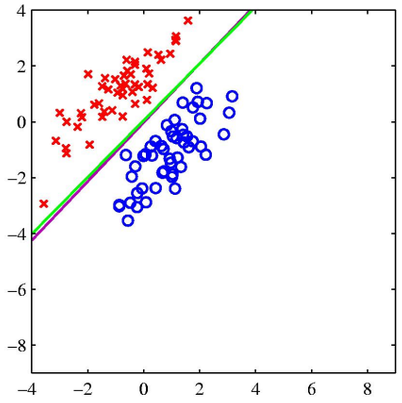
$$z(y) = \sum_{i=0}^{d'} a_i y_i, y_i = f_i(x)$$

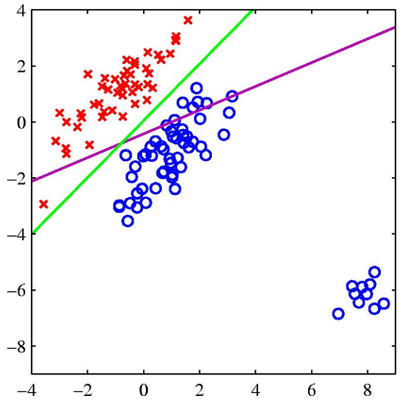
- Objetivo: ajustar a t.q.:
  - $x \in C_0$ -> $z(y)<0$.
  - $x \in C_1$ -> $z(y)>0$.

- Se elige una codificación numérica para la variable objetivo (C_0 y C_1). La elección del valor determinará el comportamiento del método. Un método bastante aceptado es usar la proporción de ejemplos de cada clase (con el signo adecuado). En este caso el método es equivalente al *Discriminante Lineal de Fisher*.
- Una vez hecho, podemos usar el método que hemos visto para regresión lineal para ajustar los coeficientes del discriminante.
- En este caso, la función de coste sería:

$$J(a) = \frac{1}{2m} \sum_{i=1}^{m} (z(y^{(i)}) - c^{(i)})^2$$

- Es un método que por lo general no produce buenos resultados, sobre todo por ser muy sensible a outliers.





Ajuste de Funciones Discriminantes: regresión logística

- Sea una función discriminante como:

$$z(y) = \sum_{i=0}^{d'} a_i y_i, y_i = f_i(x)$$

Objetivo: ajustar *a* t.q.:

- $x \in C_0 \longrightarrow z(y) < 0$
- $x \in C_1 \longrightarrow z(y) > 0$

- Es difícil interpretar z(y): ¿Qué es un z(y) grande? ¿Cómo comparar los elementos entre sí? ¿Está acotado z(y)?

- Vamos a plantearlo a partir de una función sigmoidal como:

$$\sigma(y) = \frac{1}{1 + e^{-z(y)}}$$

Objetivo: ajustar *a* t.q.:

- $x \in C_0 \longrightarrow z(y) < 0,\ \sigma(y) < 0.5.$
- $x \in C_1 \longrightarrow z(y) > 0,\ \sigma(y) > 0.5.$

- Como se puede ver, seguiremos intentando ajustar z(y), pero en este caso a partir de una función indirecta, *h*, que está acotada entre 0 y 1. Es común interpretar que $h(y)$ es la probabilidad de pertenencia a la clase C_1.
  - $z(y) > 0$ (x es de clase C_1) -> $\sigma(y) > 0.5.$
  - $z(y) < 0$ (x es de clase C_0) -> $\sigma(y) < 0.5.$

Regresión logística: Función de coste

$$z(y) = \sum_{i=0}^{d'} a_i y_i, y_i = f_i(x) \qquad \sigma(y) = \frac{1}{1 + e^{-z(y)}}$$

Objetivo: ajustar *a* t.q.:

- $x \in C_0 \longrightarrow z(y) < 0,\ \sigma(y) < 0.5.$
- $x \in C_1 \longrightarrow z(y) > 0,\ \sigma(y) > 0.5.$

- Puesto que $\sigma(y)$ varía entre 0 y 1, vamos a definir:
  - $C^{(i)} = 0$ si el ejemplo *i* pertenece a C_0.
  - $C^{(i)} = 1$ si el ejemplo *i* pertenece a C_1.
- Necesitamos definir una función de coste J, basándonos en una función de pérdida $\mathscr{L}$:

$$J(a) = \frac{1}{m} \sum_{i=1}^{m} \mathscr{L}(C^{(i)}, \sigma(y^{(i)}))$$

- Si usásemos el error cuadrático como función de pérdida no tendríamos una función convexa por la sigmiodal, y por tanto la optimización sería compleja.

Regresión logística: Función de coste

$$z(y) = \sum_{i=0}^{d'} a_i y_i, y_i = f_i(x) \quad \sigma(y) = \frac{1}{1 + e^{-z(y)}}$$

$$J(a) = \frac{1}{m} \sum_{i=1}^{m} \mathscr{L}(C^{(i)}, \sigma(y^{(i)}))$$

Objetivo: ajustar *a* t.q.:

- $x \in C_0 \longrightarrow z(y) < 0,\ \sigma(y) < 0.5.$
- $x \in C_1 \longrightarrow z(y) > 0,\ \sigma(y) > 0.5.$

$$\mathscr{L}(C, \sigma(y)) = -C \times log(\sigma(y)) - (1 - C) \times log(1 - \sigma(y))$$

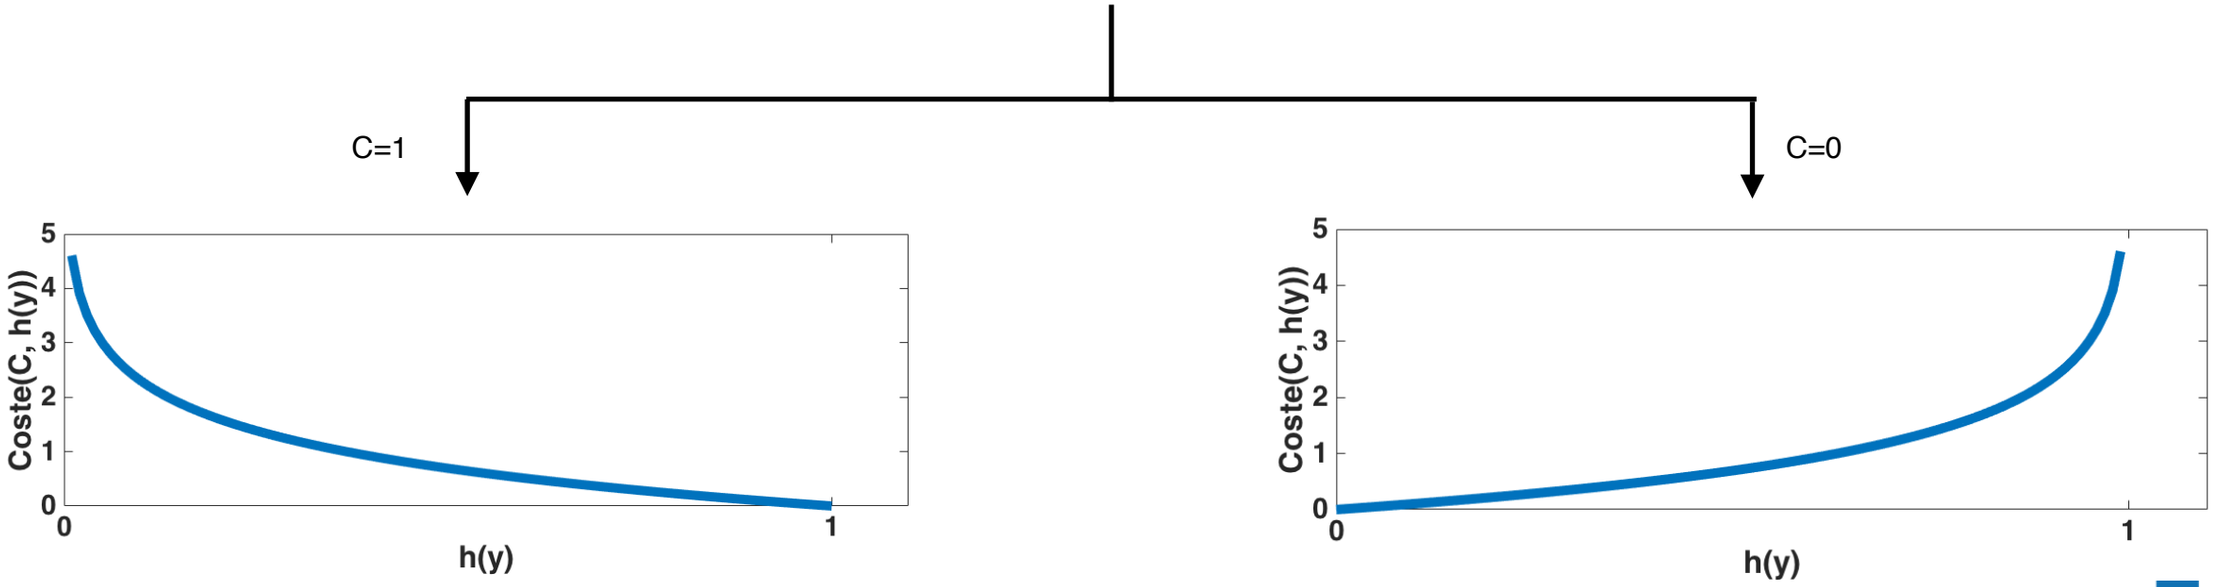
- C=1, $\sigma(y) \to 1$ entonces. $\mathscr{L}(C, \sigma(y)) \to 0$
- C=1, $\sigma(y) \to 0$ entonces. $\mathscr{L}(C, \sigma(y)) \to \infty$
- C=0, $\sigma(y) \to 1$ entonces. $\mathscr{L}(C, \sigma(y)) \to \infty$
- C=0, $\sigma(y) \to 0$ entonces. $\mathscr{L}(C, \sigma(y)) \to 0$

Represento que si C=1, para la función h la clasifica como C=

Regresión logística: Función de pérdida

$$z(y) = \sum_{i=0}^{d'} a_i y_i, y_i = f_i(x) \qquad \sigma(y) = \frac{1}{1 + e^{-z(y)}}$$

$$\mathscr{L}(C, \sigma(y)) = -C \times log(\sigma(y)) - (1 - C) \times log(1 - \sigma(y))$$



Regresión logística: Función de coste

$$z(y) = \sum_{i=0}^{d'} a_i y_i, y_i = f_i(x) \qquad \sigma(y) = \frac{1}{1 + e^{-z(y)}}$$

$$J(a) = \frac{1}{m} \sum_{i=1}^{m} \mathscr{L}(C^{(i)}, \sigma(y^{(i)}))$$

$$\mathscr{L}(C, \sigma(y)) = -C \times log(\sigma(y)) - (1 - C) \times log(1 - \sigma(y))$$

- Tenemos una función derivable, de valor cero cuando todos los puntos de ejemplo están correctamente separados.

$$\frac{\partial}{\partial a_j} J(a) = \frac{1}{m} \sum_{i=1}^{m} (\sigma(y^{(i)}) - C^{(i)}) y_j^{(i)}$$

gradiente para cada muestra individual (i)

- Se convierte en un método idéntico a la regresión lineal. Tan solo es necesario contemplar el uso de la sigmoidal en el cálculo del gradiente.

Cálculo del gradiente: regla de la cadena

Suponemos cálculo para un único ejemplo para simplificar notación: inputs $(y_0, y_1, y_2, \ldots)$, output C

- Si *g* depende de *f*:

$$\frac{\partial g}{\partial x} = \frac{\partial g}{\partial f}\frac{\partial f}{\partial x}$$

$$\left.\begin{matrix} a_0 \\ a_1 \\ \cdots \\ a_k \\ \cdots \end{matrix}\right\} \longrightarrow \boxed{z = a_o y_0 + a_1 y_1 + a_2 y_2 + \ldots} \longrightarrow \boxed{\sigma = \frac{1}{1+e^{-z}}} \longrightarrow \boxed{\mathcal{L}(\sigma, C)}$$

$$\frac{d}{dz}\sigma = \frac{d}{dz}\frac{1}{1+e^{-z}} = \sigma(1-\sigma) \qquad \frac{\partial}{\partial \sigma}\mathcal{L}(\sigma, C) = \frac{-C}{\sigma} + \frac{1-C}{1-\sigma}$$

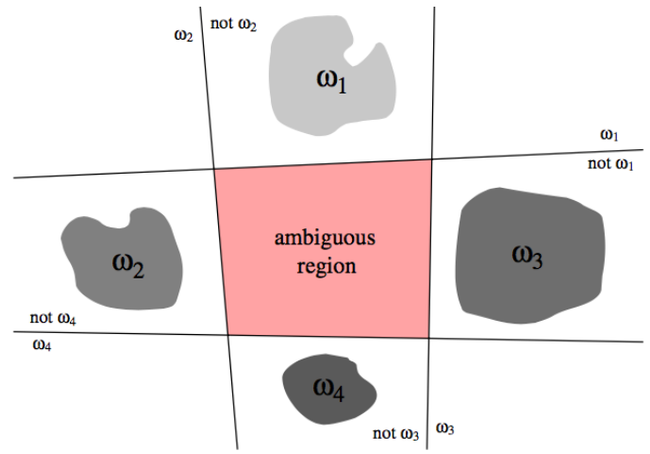
$$\frac{\partial}{\partial z}\mathcal{L}(\sigma, C) = \frac{\partial \mathcal{L}}{\partial \sigma}\frac{d\sigma}{dz}\mathcal{L}(\sigma, C) = (\sigma - C)$$

$$\frac{\partial}{\partial a_k}\mathcal{L}(\sigma, C) = \frac{\partial \mathcal{L}}{\partial z}\frac{\partial z}{\partial a_k}\mathcal{L}(\sigma, C) = (\sigma - C)y_k$$

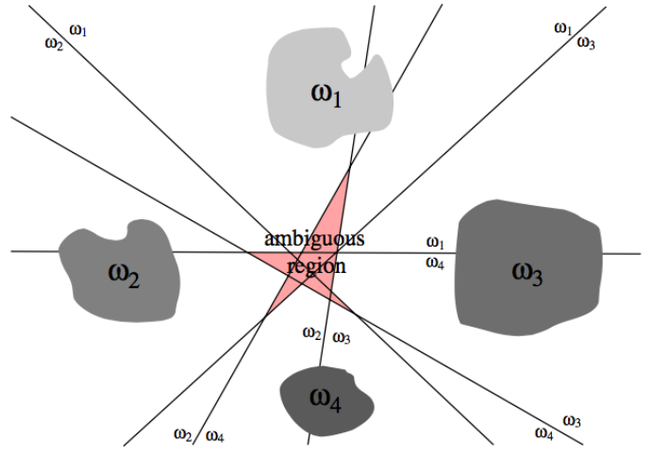
Extensión a más de dos clases

- Podemos pensar en usar varios clasificadores lineales que implementen dicotomías entre clases.

  Elaboramos un clasificador para cada clase que nos diga si un punto pertenece a la clase o no. Esto nos conduce a regiones indeterminadas.



  Elaboramos para cada clase un clasificador independiente respecto a cada una de las otras clases. También nos conduce a regiones indeterminadas.



n_c = número de clases

Extensión a más de dos clases

- La solución es determinar la función discriminante para cada una de las clases (por ejemplo mediante regresión logística) y después, dado un punto, quedarnos con aquella clase cuya función discriminante es mayor.
- Este sistema se conoce como “máquina lineal”.

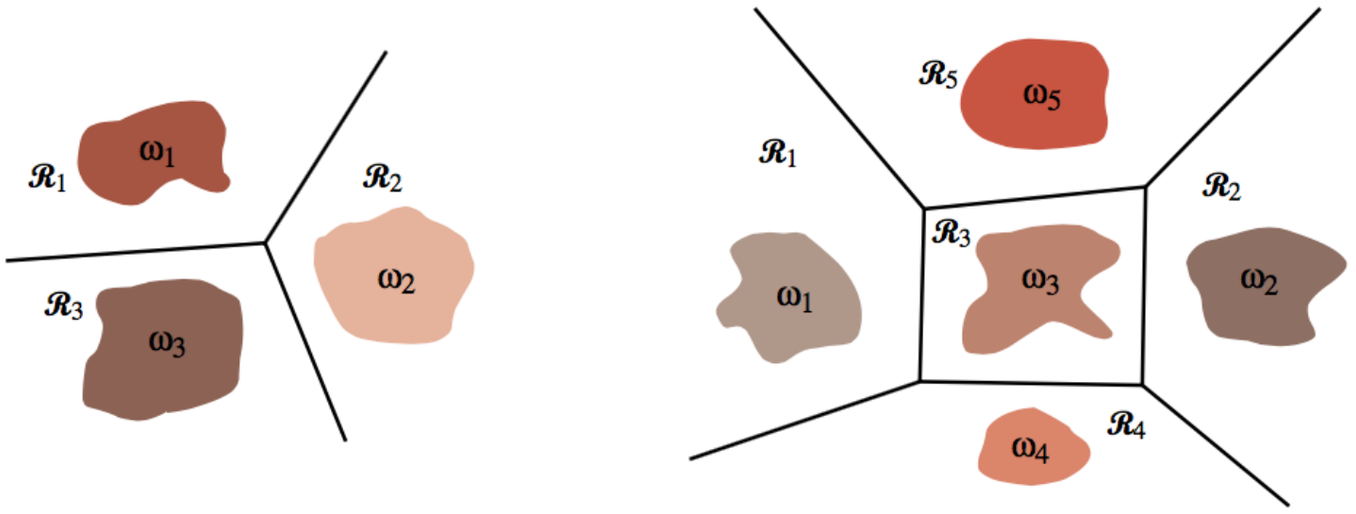


Figure 5.4: Decision boundaries produced by a linear machine for a three-class problem and a five-class problem.